AI模型

渠道测试平台

用户手册

配置 · 测试 · 复核 · 对比 · 留档

Windows / Mac ｜ 脱敏公开版

从这里找到你要做的事

01 首次启动与准备 03

02 工作台与渠道配置 04

03 基础能力检查 08

04 题库与分类管理 10

05 全量测试与自动复核 13

06 结果、用量与实际扣费 15

07 小时常规与每日 SVG 巡检 21

08 SVG 对比与性能报告留档 24

09 常见问题与排查 30

10 数据保存、迁移与术语 31

首次使用：先读第 3-7 页完成环境、渠道、价格与预算准备，再执行基础检查。只想查看历史结果，可直接阅读“结果、用量与实际扣费”。

完整解压，再打开桌面平台

无需另装 Python、Node 或浏览器；模型请求仍需要可达网络。Mac 首次打开还受系统安全策略影响。

Windows

双击“开始使用.cmd”

Windows 10 / 11 x64，需系统 .NET Framework 4.8。入口会检查随包运行组件和程序目录写入权限。请放到桌面、文档等可写目录，不要直接在压缩包预览中运行。

Mac

打开 .app 或“开始使用.command”

支持 Apple / Intel 双架构，建议 macOS 11 及以上。先运行“环境检查.command”可离线检查依赖。未签名公证时，按系统“隐私与安全性 → 仍要打开”核对来源后允许；公司策略可能需 IT 批准。

1 确认网络与凭证

内网渠道需要接入相应网络；平台能打开，不代表渠道必然可调用。

2 先保存，再执行

准备 Base URL、接口类型、准确模型名和 Key；填写后保存，确认成功提示。

3 首次用小范围验证

先选少量型号做基础检查，核对结果与费用，再开展全量测试。

公开脱敏版：渠道字段、Key、模型、历史答卷、费用和报告画面均已去标识化；实际页面菜单位置及操作路径以对应版本界面为准。

先认识工作台

顶部主菜单对应完整测试流程；子菜单把“开始操作”和“历史记录”分开。建议先完成配置，再按顺序执行。

进入路径　① 完整解压平台文件夹 → ② 双击“开始使用.cmd”（Mac 打开 APP）→ ③ 进入工作台



图 01　桌面界面示意（配置与记录已脱敏）

1 从 0 开始

先进入“渠道、模型与 Key”，添加并勾选需要测试的模型，填写凭证后保存。

2 按流程前进

基础检查 → 题库管理 → 全量测试与复核 → 结果查看；定时巡检、SVG 和报告分别查看。

3 看清所选批次

历史结果、费用和作品均按批次查看。切换页面后先确认批次名称和测试类型。

提示 本手册截图来自 Windows 桌面版的离线副本。Mac 的业务界面相同，启动与数据位置不同，见“首次启动”和“数据与迁移”。

配置渠道，添加并选择模型

每个渠道独立保存名称、接口类型、Key 与模型列表，最多同时配置四个渠道。公开截图不包含真实配置。

进入路径　① 顶部“0 渠道、模型与 Key” → ② 向下找到渠道卡片



图 02　桌面界面示意（配置与记录已脱敏）

1 填写渠道信息

在渠道卡片填写名称和 Base URL，按供应商实际支持情况选择 Chat Completions 或 Responses。

2 先添加，再勾选

输入完整模型名或渠道别名，点击“+ 添加模型”，再勾选参与测试的型号。名称必须与渠道实际接受的名称一致。

3 保存并确认

点击底部“保存设置”，以“保存成功”提示为准。添加或删除渠道、型号后也应检查选择与保存状态。

提示　“已保存 Key；留空保留”表示不输入新值会沿用已保存凭证。不要把 Key 写进题干或用于分享的截图。

按渠道和型号配置单价

“费用对比”维护价格；批次中的用量与该次调用使用的价格一起形成估算费用。估算费用与后台实扣分别保存。

进入路径 ① 顶部“费用对比” → ② 向下找到“中转模型单价”表格



图 03 桌面界面示意（配置与记录已脱敏）

1 找到对应行

按“渠道 / 型号”找到价格行，并勾选该行参与计价。不同渠道的同名模型可分别定价。

2 统一单位与币种

填写普通输入、缓存读取、缓存写入、输出单价。平台按每百万 Token 单价核算；供应商若按千 Token 报价，先换算。

3 保存与复核

确认 CNY / USD 及所有单价，再保存设置。缺少价格或缺少必需用量时，平台不会自动填零费用。

提示 不要直接把后台的 Token 数量填进单价栏。修改单价不会把旧请求的历史价格重写成新价格。

设置巡检时段与每日保护预算

“运行时段与预算”控制允许执行的星期、时间窗口以及每日请求量和计划 Token 预算。它是本机保护措施。

进入路径　① 顶部“运行时段与预算” → ② 找到“设置巡检时段、超时和每日预算”



图 04　桌面界面示意（配置与记录已脱敏）

1 设定允许时段

勾选工作日并填写开始、结束时间。定时巡检必须处于允许时段，实际执行也受队列和正在运行的批次影响。

2 预留完整调用量

每日请求和 Token 预算应涵盖题目生成、工具多轮、重试及自动复核，不只计算题目数。

3 保存后再测试

确认已保存，再开始新批次。达到预算会跳过或停止继续发送，并留下状态与原因。

提示 计划 Token 预算不是供应商的扣费硬上限；请求实际消耗和后台计费仍以接口及账单为准。

先做基础检查，确认能否正常使用

进入“基础能力检查 → 开始检查”。检查对象是已启用渠道中已勾选、已保存的模型。

进入路径　① 顶部“1 基础能力检查” → ② 子菜单“开始检查”



图 05　桌面界面示意（配置与记录已脱敏）

1 检查前确认配置

先完成渠道、Key、接口类型、模型选择及预算保存，避免因为未保存或名称不匹配而失败。

2 点击开始检查

点击“检查已勾选模型的基础能力”。确认框会提示型号数量、检查项与最低请求量，确认后开始。

3 等待自动处理

新流程用五个探针形成六项结论：文本、JSON、工具调用、工具自主闭环、受控回传、输出限制。

提示 每型号正常至少需要 7 次请求；工具轮次、参数对照和可恢复错误的重试会增加请求量与费用。基础检查结论不限制全量测试。

逐项看结论，区分答错与上游异常

进入“历史检查记录”，展开所需批次。平台按渠道和型号列出通过项目及失败、兼容或交付异常的具体原因。

进入路径　① 顶部“1 基础能力检查” → ②“历史检查记录” → ③ 点击批次行展开



图 06　桌面界面示意（配置与记录已脱敏）

1 看各项，不只看总标记

“部分通过，存在异常”表示有些能力已验证通过，同时仍有未通过或无法判定能力的项目。

2 对照错误原因

完整回答不符合规则会判未通过；HTTP 拒绝、上游流式报错等会明确标上游异常。本机预算、停止或网络问题另作说明。

3 需要时重新检查

先修正 Key、模型名、接口类型或上游问题，再运行新批次；历史批次保留当时请求与结论。

提示 基础检查会对可恢复的交付问题有限自动复核重试，等待时显示转圈。不会反复重跑正常错答来“刷通过”。

按分类和关键词找到题目

“题库管理 → 题目列表”显示当前题库数量、分类数量和匹配结果。截图是采集时的数据示例，实际数量随维护变化。

进入路径　① 顶部“2 题库管理” → ② 子菜单“题目列表”



图 07　桌面界面示意（配置与记录已脱敏）

1 先筛选分类

在分类下拉框选择题目类别；同类题集中展示，便于定位某一能力的测试项。

2 再输入关键词

可搜索题号、标题、题干和分类。点击“清空筛选”恢复全部题目。

3 查看或维护

点击“查看 / 编辑”进入题目窗口；删除前确认题号，已有测试批次中的原题与答案仍保留。

提示 全量测试使用当前有效题库，冲突或人工排除项会明确排除；它不等于只执行当前页面筛选出的题目。

先建立分类，再给题目选择分类

在“分类管理”中维护分类名称。新增或编辑题目时，分类从已有列表选择，避免同一类别被填出多种名称。

进入路径　① 顶部“2 题库管理” → ② 子菜单“分类管理”



图 08　桌面界面示意（配置与记录已脱敏）

1 新增分类

在输入框填写统一的分类名称，点击“新增分类”，确认保存提示。

2 调整名称

在现有分类行修改名称后点击“保存改名”。当前题目会随分类改名，旧测试快照不改写。

3 删除空分类

有题目的分类不能直接删除。先将题目移到其他分类，确认计数为零，再删除该空分类。

提示 修改题库或配置后，已有巡检可能暂停或需要重新确认基线；维护完成后到“已有巡检计划”核对状态。

新增或编辑一道题

题目窗口维护题号、标题、分类、题干、判分方式、参考答案和输出上限。图示为已保存题目的编辑窗口。

进入路径　① “2 题库管理” → ② “题目列表” → ③ 题目下方 “查看 / 编辑” （新题点 “新增题目” ）



图 09　桌面界面示意（配置与记录已脱敏）

1 写清题目要求

新增时填写唯一题号；已存在的题号不能直接改。选择已有分类，题干应明确格式、约束和交付物。

2 匹配判分方式

文本严格相等填原文；JSON 题填合法 JSON。代码、复杂约束和视觉题应使用对应的规则与复核配置。

3 保存并检查反馈

填写合理的最大输出 Token 后保存。高级 JSON 区用于多轮消息、工具和来源，调整前核对完整结构。

提示 题干会发给被测模型；参考答案、评分规则是判分依据，不应混入题干。保存生成新版本，历史批次仍用原快照。

使用当前题库开始全量测试

进入“全量测试与复核 → 开始全量测试”。一次批次对所有已保存勾选的型号执行当前题库。

进入路径　① 顶部“3 全量测试与复核” → ② 子菜单“开始全量测试”



图 10　桌面界面示意（配置与记录已脱敏）

1 确认本次范围

核对渠道、型号、题库与每日预算。比较渠道表现时，应尽量使用同一题库版本和相近执行条件。

2 开始并等待

点击“使用整个题库开始全量测试”，阅读请求量和额度提示后确认。可在历史批次中查看已处理题次。

3 必要时停止

点击“停止当前批次”会中断继续执行并保存已有结果；它不会补造尚未交付的答案。

提示 总并发上限为 2：不同渠道可以同时执行，同一渠道逐题执行。执行速度也受上游响应、工具轮次和复核耗时影响。

查看历史批次，等待自动复核回填

进入“历史批次与答案”，选择一个批次。每题保留冻结题干、模型原始回答、工具调用、参考及判定依据。

进入路径　① “3 全量测试与复核” → ② “历史批次与答案” → ③ 下拉选择批次



图 11　桌面界面示意（配置与记录已脱敏）

1 选择正确批次

名称格式为“日期 · 第几批 · 类型”。批次按北京时间每天从第一批开始，不累计前一天编号。

2 展开逐题记录

检查回答是否完整交付、是否进入复核。可以结合原题、答案和参考判断结论是否合理。

3 等待最终状态

作答结束后，语义、代码或视觉题可能继续自动复核。待复核未清零时，不能视为全部完成。

提示 完整交付的答案可填写人工复核结论及原因并保存。自动复核被阻断时，可在“用量与扣费”找到“启动 / 重试自动复核”，会产生额外调用。

先选一次测试，再看所有统计

“结果查看”只展示当前选中批次。先按时间和类型筛选，再选择该次测试，避免把多次记录混在一起解释。

进入路径　① 顶部“4 结果查看” → ② 筛选日期与类型 → ③ 下拉选择批次



图 12　桌面界面示意（配置与记录已脱敏）

1 筛选时间与类型

支持开始 / 结束日期和全部、今天、近 7 天、近 30 天；类型可选全量、基础、小时巡检或每日 SVG 专项。

2 选中一个批次

下拉框切换后，先确认“当前仅展示”的名称、状态和题次数量，再阅读表格。

3 按目的切子菜单

概况与费用看本次整体状态；模型对比看渠道差异；分类结果找短板；逐题答案定位具体题。

提示　“第一批”是该日期所有测试类型共用的顺序。复核、重试、刷新和重启不会为同一次测试新增批次号。

比较每个渠道和型号的表现

“本次模型对比”把同一批次中的各渠道、型号分别列出，适合横向看准确性、交付情况及可核算费用。

进入路径　① “4 结果查看” → ② 选择批次 → ③ 子菜单“本次模型对比”



图 13　桌面界面示意（配置与记录已脱敏）

1 先比较相同条件

核对型号、题库和批次。不同版本、不同题量或不同输出预算的结果，不宜直接当成公平排名。

2 同时看交付与判分

通过率要结合已判分题数、待复核数和未完整交付数看，不能只看一个百分比。

3 再比较费用

这里的费用为可核算的估算值。若显示部分估算，说明仍有请求缺少价格或必需用量。

提示 表中没有展示输入 / 输出 Token 的重复列；完整用量信息在“本次概况与费用”及“用量与扣费”中查看。

分类结果按渠道单独查看

“本次分类结果”将各渠道 / 型号分开，再按题库分类展示处理进度、通过、未通过和待复核情况。

进入路径　① “4 结果查看” → ② 选择批次 → ③ 子菜单“本次分类结果”



图 14　桌面界面示意（配置与记录已脱敏）

1 先确认渠道标题

每个分组对应一个渠道与型号，不是把所有渠道合成一张总表。

2 找出能力短板

重点观察同一分类在不同渠道中的差异，以及是否集中出现答错或未完整交付。

3 回到逐题答案

用分类筛选和题号继续定位问题，结合原始答案判断是能力、题目规则还是上游交付问题。

提示 未完整交付、未判分和待复核不是普通答错。阅读分类通过率时，需要同时查看有效判分覆盖。

搜索并展开每一道题的答案

“本次逐题答案”支持关键词、分类和结论筛选。展开后可直接看到当时题目、模型答案及判分参考。

进入路径　① “4 结果查看” → ② 选择批次 → ③ “本次逐题答案” → ④ 点击题目展开



图 15　桌面界面示意（配置与记录已脱敏）

1 先缩小范围

输入题号或关键词，也可以选择分类及通过 / 未通过 / 待复核等状态。

2 展开查看细节

点击“展开查看”，同时读题目、答案和原因。不要只凭标题或模型自称“正确”作判断。

3 有疑问再复核

如发现参考冲突或误判，记录题号与批次；到全量模块的原始记录中填写复核结论与原因。

提示 图中按 BX08 过滤的是历史答案示例，不表示当前所有型号的最新表现。

理解 Token、缓存率与“部分统计”

进入“全量测试与复核 → 用量与扣费”，选中批次。统计覆盖该次生成、工具多轮和重试；自动复核用量及合计另列。

进入路径　① “3 全量测试与复核” → ② “用量与扣费” → ③ 下拉选择批次



测试结束（27题未完整交付） · 示例日期 · 第一批 · 全量

作答 示例数值 / 示例数值 题次 · 示例数值%

已处理 示例数值 题次（含失败、跳过及排除），共 示例数值 题次；用时 51分24秒。 执行条件：串行1（历史批次）。

通过 示例数值 · 未通过 7 · 待复核 0 · 排除 2 · 未完整交付 27

本批次共 示例数值 次接口请求，示例数值 次返回基础用量。以下数字只合计已取得的数据，缺失请求不按 0 计算。

用量类型	已统计用量	有数据的请求数
总Token（输入+输出）	示例数值（部分统计）	示例数值 / 示例数值 次
输入（含缓存）	示例数值（部分统计）	示例数值 / 示例数值 次
输入扣除缓存读取（含可能的写入）	示例数值（部分统计）	示例数值 / 示例数值 次
输出（含推理）	57,示例数值（部分统计）	示例数值 / 示例数值 次
缓存读取	54,示例数值（部分统计）	示例数值 / 示例数值 次
缓存写入	接口未返回缓存写入量	0 / 示例数值 次

图 16　桌面界面示意（配置与记录已脱敏）

1 先看数据覆盖

每一类型都显示有数据的请求数。输入、输出齐全，不代表缓存写入或推理拆分也齐全。

2 避免重复相加

缓存读取包含在输入中，推理包含在输出中。总 Token 通常为输入加输出，不再加一遍缓存或推理。

3 正确解释缓存率

有完整缓存明细时，按缓存读取 Token / 输入 Token 加权计算；部分样本的缓存率不等于整个批次。

提示　“部分统计”表示上游没有给全数据，缺失不等于 0；重试成功也不能补出前一次失败请求的隐藏消耗。平台不会把客户端估算冒充实测。

登记后台实扣，完成批次对账

同一“用量与扣费”页面下方提供“后台实际扣费（批次对账）”。它与配置单价形成的估算费用分别保存。

进入路径 ①“3 全量测试与复核” → ②“用量与扣费” → ③ 选批次 → ④ 向下找到“后台实际扣费”



图 17 桌面界面示意（配置与记录已脱敏）

1 取得可归属的账单

优先使用后台该批次的调用账单。用余额差时，先排除充值、退款、其他调用及结算延迟。

2 填写金额和依据

输入非负实扣金额、币种以及账单编号或时间范围，点击“登记 / 修正实扣”。

3 看差额是否可比较

只有估算覆盖完整、币种一致时才显示可核算差额；缺项时不把不完整估算直接当成真实优惠。

提示 不能用后台总金额反推出准确的缓存率或各类 Token。接口用量、价格估算与实际扣费是三种不同证据。

建立小时常规巡检计划

“定时巡检 → 创建巡检计划”用于持续观察渠道稳定性。小时常规默认使用五道客观题，避免每小时都做耗时的视觉评分。

进入路径　① “5 定时巡检” → ② “创建巡检计划” → ③ 计划类型选 “小时常规巡检”



图 18　桌面界面示意（配置与记录已脱敏）

1 选计划与型号

先确认已保存勾选的渠道 / 型号，再选择 “小时常规巡检”。填写有效、不同的题号。

2 确认选题依据

当前模板含工具、JSON 业务、两种难题及长上下文题。填写依据，不要只挑过于简单或同一题族的题。

3 启用后看状态

点击 “启用所选计划”，到 “已有巡检计划” 确认。相同类型的已启用计划不可重复创建。

提示 巡检题目请按测试目标自行选择，并以已保存计划显示内容为准。

把绘图放到每日 SVG 专项

选择“每日 SVG 专项”，使用 HTML02 鹈鹕与 HTML01 鳄鱼各一道。当前约定为工作日北京时间 17:00。

进入路径　① “5 定时巡检” → ② “创建巡检计划” → ③ 计划类型选 “每日 SVG 专项”



图 19　桌面界面示意（配置与记录已脱敏）

1 选择每日专项

切换计划类型后，检查题号与每日执行时间。每日时间应落在全局允许时段内。

2 独立保存结果

每日绘图形成独立的“SVG专项”批次，可在结果查看或 SVG 模块选择，不与小时客观题混算。

3 理解同点排队

17 点小时常规与每日专项都到期时，会先后执行，共用总并发 2，不会各自额外开两路。

提示 SVG 生成、渲染和视觉复核都需要时间，语义 / 视觉复核会调用模型并计入该批次费用。

管理计划，确认是否真的会执行

“已有巡检计划”显示计划类型、启停状态、时段和最近事件。公开包不预置巡检计划。

进入路径 ① 顶部“5 定时巡检” → ② 子菜单“已有巡检计划”



图 20 桌面界面示意（配置与记录已脱敏）

1 核对已启用 / 已暂停

导出包默认暂停，接收者确认渠道后再创建启用所需计划。改动配置或题库后也应回来检查。

2 保持平台运行

APP 和本地服务需要持续运行，电脑应保持唤醒且网络可达；它不是关机后仍运行的云端定时任务。

3 看最近执行事件

排队、已开始、错过窗口或调度错误都会留记录。错过窗口不会跨日无限追补，避免重复费用。

提示 当前列表可“暂停此计划”。暂停后需要再次执行时，到创建页核对题目和型号后重新建立计划；旧批次不删除。

按日期选择 SVG 历史批次

“鹅鹕 / 鳄鱼 SVG → 结果列表”先按时间筛选，再逐行打开一个批次，避免所有作品混在一页。

进入路径 ① 顶部“6 鹅鹕 / 鳄鱼 SVG” → ② 子菜单“结果列表”



图 21 桌面界面示意（配置与记录已脱敏）

1 筛选时间

用起止日期或快捷按钮缩小范围；只有含 SVG 作品的相关批次才有可查看的内容。

2 打开某次结果

点击该行“查看作品与评分”，进入该次测试的作品对比。

3 分清两个题号

HTML02 是鹅鹕，HTML01 是鳄鱼。题目修改后，历史批次继续使用原快照和原评分规则。

提示 查看既有结果与作品预览不调用模型。重新测试或重新执行视觉复核则会产生新的请求。

横向比较鹈鹕作品与分数

作品按动物分行、按渠道并排，每个卡片显示型号、百分制分数、结论和动画。可直接比较各渠道表现。

进入路径 ① “6 鹈鹕 / 鳄鱼 SVG” → ② “结果列表” → ③ 批次行 “查看作品与评分” → ④ 鹈鹕行



图 22 桌面界面示意（配置与记录已脱敏）

1 先看分数与状态

有评分才显示实际得分；尚未评分不显示为 0。不能只凭能预览出图就判断通过。

2 再看作品与依据

观察物种形态、骑行姿态及画面质量，展开 “评分依据” 查看分项和原因。

3 必要时打开大图

点击 “查看大图 / 动画” 检查细节；点击 “原文与复核” 回到该批次的原始答案。

提示 截图为历史批次，分数仅作界面示例。当前题面明确要求海边 SVG 动画、车轮转动及双脚踏板联动，单 HTML 交付。

鳄鱼同样按一行进行渠道对比

向下查看鳄鱼一行，保持相同观察尺度。两个、三个或四个渠道均在同一动物行中并排展示。

进入路径 ① “6 鹈鹕 / 鳄鱼 SVG” → ② “结果列表” → ③ “查看作品与评分” → ④ 下滑至鳄鱼行



图 23 桌面界面示意（配置与记录已脱敏）

1 同题、同批次比较

先确认批次与题目版本；不要把旧题的分数直接当成新海边动画题的成绩。

2 核对必过条件

当前规则要求总分至少 80、蹬踏联动至少 15/25，并满足 HTML、SVG、动物、自行车、海边及动画条件。

3 不要忽略动画要求

静态图、只整体平移或仅有装饰运动不能代替骑行动画。完整分项以该批次冻结规则为准。

提示 “禁止查看现有资产”是被测提示词约束。没有资产访问日志时，平台不能独立证明该行为是否遵守，不凭模型自述下结论。

上传外部性能测试报告

性能压测在外部工具中完成，本模块负责原件留档与查看，不会在这里向模型发起压测。

进入路径　① 顶部“7 性能报告留档” → ② 子菜单“上传报告”



图 24　桌面界面示意（配置与记录已脱敏）

1 准备支持的文件

报告需为 UTF-8 编码的 .md、.html 或 .htm，单文件不超过 4 MB。

2 选择文件与说明

点击文件选择框，选择本机报告；填写测试环境、时间或用途，便于后续追溯。

3 上传并确认

点击“上传并留档”，等待成功提示。原始文件字节、文件名、上传时间和 SHA-256 一起保存。

提示 HTML 预览不执行报告脚本，也不加载外部资源；依赖脚本、远程图片或在线字体的效果可能与原文件在浏览器中不同。

筛选、预览、下载或删除报告

“已归档报告”每份一行，显示名称、上传时间、大小和说明，操作以按钮呈现。

进入路径　① 顶部“7 性能报告留档” → ② 子菜单“已归档报告”



图 25　桌面界面示意（配置与记录已脱敏）

1 按上传时间筛选

设置日期范围，或使用今天、近 7 天等快捷入口。没有匹配项时可清空时间恢复查看。

2 预览或下载原件

“预览报告”在桌面APP内打开；“下载原文件”进入系统保存对话框，选择位置后保存。

3 删除需确认

“删除记录”会从当前列表移除，并取消该记录的预览 / 下载入口。内部保留原件和删除记录供维护恢复。

提示 不要直接改写 data/performance 内的原件；平台会用大小和哈希检查，文件缺失或被改动时会明确报错。

在 APP 内预览，保存原始文件

图中为实际 HTML 报告的桌面预览。预览用于阅读；下载保存的是归档原件，不是页面截图或重新生成的文本。

进入路径　① “7 性能报告留档” → ② “已归档报告” → ③ 对应报告行 “预览报告”



图 26　桌面界面示意（配置与记录已脱敏）

1 阅读静态内容

查看标题、正文、表格和已展开图表。为避免正文空白，部分动画显示效果会转为静态展开。

2 保存到本机

点击右上 “下载原文件” ，在 Windows 或 Mac 系统对话框中选位置；成功后平台会反馈保存结果。

3 异常时核对原件

若提示原文件不存在或校验不符，确认迁移时保留原件目录；必要时重新上传正确的原文件。

提示 取消系统保存对话框只取消这次下载，不删除平台中的归档。预览中的功能按钮或脚本不一定可运行。

常见问题：先分清是哪一层的问题

遇到的情况	建议处理顺序
双击后没有窗口	Windows：确认完整解压、目录可写、系统 .NET 4.8；查看程序/logs/desktop-start.log。Mac：运行环境检查，查看用户日志目录。
平台能打开，渠道调用失败	检查内网 / VPN、Base URL、接口类型、模型名、Key 与额度；HTTP 400、401、限流和上游报错应按具体原因处理。
基础检查“部分通过”	逐项看已验证能力、未通过项目与上游 / 执行异常。修正原因后新开检查批次；基础检查不会锁住全量测试。
作答 100%，仍在转圈	可能正在自动复核。待复核完成后会回填原批次；如复核被阻断，检查原因后再点击启动 / 重试自动复核。
Token 或费用显示“部分统计”	上游未给全字段或某些失败请求没有 usage。缺失不是 0；需要后台逐请求明细或账单补充，不能靠重跑还原旧请求。
巡检没有按时执行	确认计划启用、工作日和时段正确、APP 与本地服务仍运行、电脑唤醒、预算可用。看最近事件，区分排队和错过窗口。
报告预览与原网页效果不同	报告预览禁止脚本和外部资源。先确认静态正文；需要原始效果时下载原件，在适合的环境中查看。
怀疑某题判错	保存批次、渠道、题号、原答与原因；核对冻结参考。对完整交付的记录填写复核原因，不直接把上游失败改成能力答错。

数据保存、迁移与常用术语

平台	配置与数据位置	迁移与更新
Windows	解压目录 / 程序/config.json；题库、批次、答案、费用与计划在程序/data。	退出平台后复制完整文件夹。不能只复制 EXE，也不能只复制一个数据库而丢掉证据和报告原件。
Mac	~/Library/Application Support/FutongChannelModelTest/program；配置为config.json，业务数据在data。	首次启动从包内初始化，之后保留个人数据。换电脑前退出程序，复制该用户数据目录；仅更新 APP 不覆盖个人历史。

几个容易混淆的概念

术语	含义
批次 / 题次 / 请求	一次测试是一个批次；一道题乘一个型号是一题次；工具、重试与复核可能让一题次产生多次请求。
交付完成 / 判分完成	取得完整回答才具备交付证据；复核结论回填后，才能形成该次的最终判分。
输入 / 输出 / 缓存 / 推理	缓存读取包含在输入中，推理包含在输出中，统计时不重复加总。真实缓存率依赖上游缓存明细。
估算费用 / 实际扣费	估算来自实际可得用量与已配置单价；实扣来自后台账单，两者分开保存和核对。

迁移包中的巡检默认暂停，避免两台电脑重复调用。操作前先保存；退出时如有测试进行，按提示停止并等待已有结果保存。